

前沿研究调研报告

# 机器人灵巧手 + 世界动作模型 (WAM)

过去两年研究脉络、论文成果、硬件数据、指标与可复现性分析

资料时间窗: 2024-08-21 - 2026-08-21

覆盖严格 WAM、动作条件世界模型、预测视觉表征, 以及触觉原生 WAM

交付版本: 2026-08-21

阅读提示: 报告将“灵巧手结果”和“通用 WAM 结果”分层比较。凡使用并联夹爪或双臂平台的工作, 均会明确标注, 避免把高分仿真结果直接解释为多指灵巧手能力。

# 执行摘要

## 结论先行

过去两年的主线不是简单地把视频生成器接一个动作头，而是逐步让“未来状态”真正参与动作学习、动作规划和闭环执行。2024 年末的 VPP 证明视频预测表征能提升 XHand 灵巧手策略；2025 年的 UVA 和 UWM 建立了视频-动作联合建模与动作无标签视频共训的基础；2025 年末至 2026 年，研究开始直接处理跨形态灵巧手、触觉接触、语义视觉-动作表示和大规模异构数据。

就“机器人灵巧手 + WAM”的交集而言，最直接的证据来自 VPP、Cross-Embodiment World Models、DexWM、Dream-Tac、TouchWorld 和 N0-TWAM；DreamZero、Cosmos Policy、LingBot-VA/2.0、UWM、UVA 和 RepWAM 则提供了 WAM 的架构、数据规模和训练范式，但多数实验使用并联夹爪、双臂或通用机械臂。当前的关键瓶颈不是“能否生成未来视频”，而是“未来预测是否包含手指接触、物体受力、滑移、形态差异和可执行动作”。

本报告的综合判断: WAM 正从像素级想象转向动作相关表征与触觉前瞻；多指手仍是开放问题。短期内最具性价比的研究路线，是用可复现的 latent/3D 手-物状态作为世界目标，先在仿真和公开数据上验证，再把触觉、接触事件和模型预测控制加入闭环。

| 维度       | 本报告结论                                                                        |
|----------|------------------------------------------------------------------------------|
| 发展阶段     | 预测表征 -> 联合视频-动作 -> 跨形态/3D -> 基础模型 WAM -> 触觉原生 WAM                            |
| 灵巧手证据    | 直接多指硬件数量仍少；XHand、Ability、Allegro、Leap、Shadow、Wuji、Inspire 的证据最接近目标           |
| 最重要的表示   | 像素/latent 便于规模化；DINO/语义 latent 提升 OOD；3D particles/flow 更贴近形态与接触；触觉提供视觉不可见状态 |
| 最重要的工程问题 | 视频生成推理慢、世界模型漂移、动作与未来状态错位、真实触觉/硬件数据难公开                                        |
| 复现性      | UWM、Cosmos、LingBot-VA、DreamZero 的软件资产较完整；触觉和跨手工作往往缺少数据或大规模预训练管线              |

## 数据来源与核验方法

本报告以论文原文/ arXiv HTML 或 PDF 为主证据，项目主页和官方 GitHub/Hugging Face 页面用于核验公开代码、权重、数据、硬件和运行要求。指标优先抄录论文表格，若论文正文与附录、项目页或不同版本存在不一致，则显式标注。访问和状态判断截止 2026-08-21。

复现性不是“有 GitHub 链接”这一项布尔值，而是综合代码/权重、数据、硬件/基准、训练算力/配方四项。报告中的等级是对公开资产的研究者视角评估，不是论文作者自报。

## 1. 范围、定义与比较口径

### 1.1 WAM 的操作性定义

本报告把 WAM（World Action Model）定义为：模型在动作预测之外，显式预测未来世界状态，并使该未来参与动作生成、动作评分、规划或训练。未来状态可以是像素、视频 latent、DINO/语义特征、3D 点/流、手-物状态或触觉。严格 WAM 往往联合建模  $p(a, o' | o, l)$ ，但推理时可以只解码动作；只要未来状态目标在训练或规划中承担动作相关作用，仍归入严格 WAM。

| 类别       | 报告中的判据                                              | 代表工作                                                        | 如何解读                           |
|----------|-----------------------------------------------------|-------------------------------------------------------------|--------------------------------|
| 严格 WAM   | 未来状态与动作在同一世界-动作建模目标中耦合，或由未来直接导出动作                   | UVA, UWM, DreamZero, LingBot-VA, Cosmos, Dream-Tac, N0-TWAM | 最接近用户所说的 WAM；重点看闭环、因果和动作-未来一致性 |
| 动作条件世界模型 | 先学 $f(s,a) \rightarrow s'$ ，再用 MPC/采样规划；策略与世界模型可以分离 | Cross-Embodiment, DexWM, DWM                                | 更容易解释物理状态和跨形态，但推理成本和状态估计更高     |

| 类别         | 报告中的判据                         | 代表工作     | 如何解读                              |
|------------|--------------------------------|----------|-----------------------------------|
| 预测视觉表征策略   | 视频模型主要作为视觉编码器或预测表征，动作策略独立训练    | VPP      | 是 WAM 的重要前身，但不要等同于联合 WAM          |
| 世界模型数据/模拟器 | 用生成世界模型产生人手数据或可交互视频，不直接等于机器人策略 | Wh0, DWM | 关注数据规模、场景/形态对齐和 simulator-to-real |

### 1.2 评价指标的不可比性

当前工作没有统一 benchmark：策略论文常报 success rate 或 task progress；latent 世界模型报 embedding L2、PCK；粒子模型报 Chamfer Distance/EMD；视频模型报 PSNR、SSIM、LPIPS、DreamSim 或 gFVD；动作迁移还会报 OLS。一个视频重建指标高的模型，不一定接触动力学正确；一个仿真成功率高的模型，也不一定能在真实多指手上稳住物体。因此下面既列原始指标，也给出“指标回答了什么问题”。

## 2. 过去两年的发展脉络

| 时间         | 阶段          | 代表工作                                        | 关键变化                                              |
|------------|-------------|---------------------------------------------|---------------------------------------------------|
| 2024.12    | 预测视觉表征      | VPP                                         | 视频扩散模型的内部表征辅助动作扩散策略，首次在 XHand 灵巧手上给出清晰收益          |
| 2025.02-04 | 统一视频-动作     | UVA; UWM                                    | 联合 latent、动作无标签视频共训、策略/正向/逆向动力学统一                 |
| 2025.11-12 | 3D 与灵巧手世界模型 | Cross-Embodiment; DexWM; DWM                | 3D 粒子、手关键点、latent 手-物交互和可控视频模拟进入主线                |
| 2026.01-02 | 基础模型化 WAM   | Cosmos Policy; LingBot-VA; DreamZero        | 预训练视频 backbone、大规模异构机器人数据、因果 AR、跨 embodiment 和零样本 |
| 2026.06    | 表示与触觉       | Dream-Tac; RepWAM                           | 未来状态从像素扩展到触觉/语义 visual-action token               |
| 2026.07-08 | 接触原生与最新扩展   | EgoWAM; LingBot-VA 2.0; N0-TWAM; TouchWorld | 3D flow、触觉未来、触觉闭环、原生语义动作预训练成为下一波方向                |

### 趋势图解

研究对象的重心沿着三条轴移动：

- 世界状态轴: RGB 像素 -> VAE latent -> DINO/语义 latent -> 3D flow/particle -> 视觉-触觉未来。
- 控制轴: 单步 BC -> action chunk -> MPC/mental rollout -> 因果自回归闭环 -> 异步预测与动作执行。
- 数据轴: 少量真实轨迹 -> 公共多 embodiment 机器人数据 -> 人类第一视角视频 -> 世界模型生成的人手数据 -> 大规模同步触觉。

这三条轴并不是同时成熟：最强的通用 WAM 仍多在并联夹爪或双臂平台上验证；最接近灵巧手的工作往往受限于硬件、数据和复现成本。

## 3. 重点工作逐篇分析

本节按研究脉络而非论文发布时间排序。每篇都补齐研究目的、硬件、数据、模型目标、指标、公开资产和复现判断。

### VPP: Video Prediction Policy | 2024.12

定位: 预测视觉表征策略 / 灵巧手前身 | 公开状态: 论文、项目页、GitHub 公开；自采数据和硬件非标准化

#### 研究摘要

研究目的: 用视频扩散模型的内部时空表征作为 vision encoder，再由 action diffusion policy 输出动作，验证“预测世界”是否能改善泛化，而不把视频生成直接当控制器。

硬件: Franka Panda; XArm + 12-DoF XHand。人类演示使用 Vision Pro 采集手指动作, 再 retarget 到 XHand, 并用低层 PD 平滑。

数据: Panda 约 2,000 条轨迹、30+任务; XHand 正文写约 3,000 条、100+任务、13类。补充材料写约 2,500 条、100+任务、10类, 报告按正文并保留这一版本差异。视频模型训练约 2 天、8 张 A100。

指标: CALVIN ABC->D 相对提升 28.1%; 真实 XHand seen 平均成功率 74.9%, unseen 60.5%, 明显高于 DP、Susie、GR1。

研究判断: 它证明了预测表征对多指手有用, 但动作头与视频世界模型不是同一个联合 WAM; XHand 结果是本方向的重要起点, 不宜当作 strict WAM 的最终证据。

复现性判断: 中等。代码公开、论文给出硬件和训练细节; 但核心 XHand/Panda 数据与采集环境不是标准公开 benchmark, 完整复现需要同类硬件和自采轨迹。

关键限制或读者应注意: 正文与补充材料的 XHand 轨迹/类别统计不一致, 应在复现实验中固定版本并记录数据清单。

公开资料: 论文 | 项目主页 | 代码

## UVA: Unified Video Action Model | 2025.02 / RSS 2025

定位: 严格 WAM 的早期统一 latent | 公开状态: 论文、项目页、代码公开; 主要依赖公共数据

### 研究摘要

研究目的: 在统一 video-action latent 中联合优化视频和动作, 同时用两个轻量 diffusion head 解耦视频/动作解码, 使策略推理跳过视频生成, 并通过 mask 训练支持 forward/inverse dynamics。

硬件与数据: 项目页明确采用公共数据和 OOD 评测, 包含 UMI 任务、LIBERO 等; 训练 UMI 时从三个数据集各采样 500 条轨迹, 8 张 H100, 视频预训练约 2 天, 联合训练再约 2 天。

指标: 以双块推向目标的 forward-dynamics 规划为例, Diffusion Policy 平均成功率 38%, 加入 UVA 未来观测选择轨迹后 60%, 真实模拟器上限 75%; 视频未来预测为 4 帧。

研究判断: UVA 解决了“联合训练但推理太慢”的矛盾, 提出 decoupled decoding, 是 UWM、DreamZero 等后续动作-未来分工的关键前驱。它的世界目标仍主要是视觉, 不覆盖多指接触。

复现性判断: 中高。公共数据、公开项目页和代码使仿真/UMI 复现较友好; 完整性能仍需要 UMI 硬件、相同数据采样和 H100 级训练。

关键限制或读者应注意: UVA 的优势在统一 latent 和推理解耦, 不等价于真实接触物理模型。

公开资料: 论文 | 项目主页 | 代码

## UWM: Unified World Models | 2025.04 / RSS 2025

定位: 统一视频、动作与动作无标签视频 | 公开状态: 论文、项目页、GitHub、checkpoint/数据链接公开

### 研究摘要

研究目的: 在一个 transformer 中联合建模 future image 和 action diffusion, 独立设置视频/动作 diffusion timestep; 通过把 action token 全噪声化处理 action-free video, 统一支持 policy、forward dynamics、inverse dynamics 与 video predictor。

硬件与数据: DROID Franka Panda, 双场景相机 + wrist 相机, 10 Hz, delta end-effector pose + gripper。预训练 2,000 条 DROID 轨迹加 2,000 条 action-free DROID; Stack Bowls、Block Cabinet、Paper Towel、Hang Towel、Rice Cooker 五任务, 各 50/50/100/50/150 demos。也覆盖 LIBERO-90 预训练和 LIBERO-10 评测。

模型与算力: 12-block DiT 风格网络、ResNet-18 observation encoder、SDXL VAE、224px 图像、16-step action horizon; 100K steps, 4 张 A100 约 24 小时, DDP。

指标: 五个真实任务中 UWM 预训练/共训在 ID/OOD 均居前，最高相对基线提升约 20%；OOD Stack Bowls 共训 21/30 成功，Block Cabinet 15/30；未来图像预测优于只预测当前图像的 ablation。

研究判断: UWM 是公开、可操作、适合做基线的 WAM。它把“动作无标签视频”变成可用数据，但硬件仍是并联夹爪，未来图像可能存在视觉伪影。

复现性判断: 高-中。代码、数据 wrapper、LIBERO/DROID checkpoint 和 4-A100 配方相对完整；真实复现仍需 DROID/Franka 采集环境。

关键限制或读者应注意: UWM 的强项是可复现的联合建模范式，不是多指灵巧手或触觉建模。

公开资料: 论文 | 项目主页 | 代码/数据

## Scaling Cross-Embodiment World Models for Dexterous Manipulation | 2025.11 / IROS 2026

定位: 3D 粒子世界模型 + 跨形态灵巧手 MPC | 公开状态: 论文 v3 和项目页公开；截至截点未检索到官方代码/数据仓库

### 研究摘要

研究目的: 把手和不同机器人手都表示为 3D 粒子集合，把动作表示为粒子 displacement field，从 joint space 迁移到共享几何空间；图网络 world model 再配合 MPC 控制新硬件。

硬件与仿真: SAPIEN 刚体 pushing、Rewarped 可微多物理 plasticine；6 类手包括 Ability 6 DoF、Allegro 16、XHand 12、Leap 16、Shadow 24 及变体。每任务约 100 条随机轨迹。真实平台为 7-DoF XArm7 + Ability Hand/XHand，4 台 RealSense；每类人类任务约 30 分钟。

任务与指标: 刚体物体推到目标方向、plasticine 重塑到目标点云；仿真看 unseen-hand MSE，真实看 Chamfer Distance/CD 和 EMD。人类+仿真 1:1 co-train 最好；Ability held-out CD  $6.95e-3$ 、EMD 4.92，XHand CD  $6.85e-3$ 、EMD 4.78。真实展示了 Ability/XHand 用同一粒子模型塑形黏土，但未给出明确成功率。

研究判断: 这是“灵巧手与世界模型”交集里最有代表性的 embodiment-agnostic 路线；它不属于 strict video-action WAM，而是更物理、可解释的 action-conditioned WM + MPC。

复现性判断: 低-中。论文细节和评测结果公开，但没有同等完整的官方训练代码、数据或一键复现管线；真实硬件门槛高。

关键限制或读者应注意: 项目页称同一模型成功重塑黏土，但结果以定性为主，不能与 success-rate 论文直接横比。

公开资料: 论文 v3 | 作者/项目页

## DexWM: World Models for Hand-Object Interactions from Human Videos | 2025.12

定位: 人类视频 latent WM + MPC + 灵巧手迁移 | 公开状态: 论文、GitHub、Hugging Face 数据公开；大数据和大算力

### 研究摘要

研究目的: 从人类视频学习 hand-object dynamics。状态用 patch-level embedding，动作是 3D hand keypoint difference + camera pose；加入 hand-consistency loss 让未来 latent 保持手的运动一致性，再用 CEM 在 latent world model 中规划。

硬件与数据: EgoDex 829 小时、194 任务、500 物体，25 个手关键点/手和相机位姿；DROID 100 小时作机器人视觉对齐；RoboCasa 约 4 小时随机探索数据作为 embodiment bridge。真实为 Franka Panda + Allegro gripper，7 arm + 16 hand，共 23 joints。

指标: HC loss 让 4 秒 PCK@20 从 26% 提升到 60%，平均从 52% 到 69%；RoboCasa reach/place/grasp 平均约 53%，同人类数据训练 DP 约 4%；真实 grasp 10/12=83%，无真实 finetune。CEM 规划每回合约 38-168 秒，默认 8 张 H100。

研究判断: DexWM 是“人类手视频 -> 机器人多指手”的实证桥梁, 说明未来预测可以承载细粒度手-物动力学; 代价是用 4 小时仿真数据桥接 embodiment, 且 open-loop 规划慢。

复现性判断: 中等。代码、模型训练脚本和 RoboCasa 随机数据公开, 算法复现性较好; 但 EgoDex/DROID 约 1.74 TB、默认多节点训练和 Allegro/Franka 硬件使完整复现昂贵。

关键限制或读者应注意: 它的成功率来自仿真规划迁移, 不能直接推断对真实接触分布和长时闭环稳定性。

公开资料: 论文 | 代码 | 数据

## DWM: Dexterous World Models | 2025.12 / CVPR 2026

定位: 动作条件视频模拟器 / 场景-动作世界模型 | 公开状态: 代码 Apache-2.0; 数据构建和真实动态评测部分不完全开放

### 研究摘要

研究目的: 输入静态场景、手 mesh 和 egocentric camera trajectory, 生成 action-conditioned 动态视频; 用 residual dynamics 和 inpainting prior 把几何/动作控制与真实手-物动态结合, 再用 VideoCLIP/LPIPS 为候选动作排序。

数据与硬件: 合成 TRUMANS 的对齐 interaction/static scene/hand mesh triplet; TASTE-Rob 固定相机真实视频; Aria glasses 的动态真实评测。论文正文写 60 个样本, 附录当前数据写 48 个, 报告保留该差异。三类各 48 个 held-out sample、3 个随机种子。无机器人硬件部署。

指标: 合成动态视频 Ours PSNR/SSIM/LPIPS/DreamSim=25.031/.844/.289/.086; 真实静态=21.547/.816/.227/.057; 真实动态=21.654/.550/.557/.225。混合 TRUMANS + TASTE-Rob 优于单一来源。

研究判断: DWM 是评测/规划用 simulator, 不是机器人策略; 它对多指手的 scene-action controllability 很有启发, 但像素质量不能替代手指接触和力学指标。

复现性判断: 中等。代码、预处理和 split 文件较完整, 算法可以复现; 但 5B 训练需 80GB 级 GPU, 真实动态数据获取与 3D 重建仍是门槛。

关键限制或读者应注意: 论文中“60”与附录“48”样本数不一致, 真实动态场景也没有机器人闭环控制结果。

公开资料: 论文 | 项目主页 | 代码

## Cosmos Policy | 2026.01 / ICLR 2026

定位: 预训练视频模型直接变成策略、世界模型和值函数 | 公开状态: 代码、模型、训练数据公开; 训练算力很高

### 研究摘要

研究目的: 对 Cosmos-Predict2-2B 做单阶段 post-training, 不改架构; 把 action、future state image/proprio 和 value 都编码成 latent frames, 在原生 latent diffusion 中联合生成, 再用 best-of-N 做模型预测规划。

硬件与数据: LIBERO/ RoboCasa 中为 Franka Panda; 真实 ALOHA 双臂, 4 个任务共 185 demos, 25 Hz、50-step action chunk。LIBERO 每套 500 demos; RoboCasa 24 个厨房任务, 每任务仅 50 人类 teleop demos, OOD 物体/场景评估。

指标: LIBERO 平均成功率 98.5%; RoboCasa 67.1%, 仅 50 demos/task; 真实 ALOHA 综合 score 93.6%, 模型预测规划在两个难任务平均再提升 12.5 个百分点。训练约 48 小时: LIBERO 64xH100、RoboCasa 32xH100、ALOHA 8xH100。

研究判断: Cosmos 把 WAM、policy、value 统一到一个预训练视频模型, 证明未来 state/value 可直接服务规划; 但多指手仍未覆盖, 真实规划每 action chunk 约 5 秒的延迟是明显限制。

复现性判断: 高-中。官方发布代码、checkpoint、训练数据和 LIBERO/RoboCasa/ALOHA 配方; 推理显存 6.0-8.9GB 友好, 但训练需 8-64 张 80GB H100。

关键限制或读者应注意: 高分主要来自模拟和 ALOHA 双臂, 不能直接代表灵巧手接触能力; 规划结果还依赖额外 rollout data。

公开资料: 论文 | 项目主页 | 代码/模型/数据

# LingBot-VA: Causal World Modeling for Robot Control | 2026.01 / RSS 2026

定位: 因果自回归视频-动作 WAM | 公开状态: 论文、Apache-2.0 代码、权重和部分数据公开

## 研究摘要

研究目的: 用交错的 video/action latent 和双流 MoT 进行 causal AR 生成; KV cache 保留长期历史, Noisy History Augmentation 允许动作从部分去噪 latent 解码, 异步执行把预测与机器人动作并行。

数据与硬件: 论文列出 AgiBot、RoboMind、InternData-A1、OXE/OpenVLA、UMI、RoboCOIN 六个来源, 总约 16K 小时机器人操作数据, 1.4T tokens; RoboTwin 2.0 用 2,500 clean + 25,000 randomized demos, 50 tasks。真实评测为双臂物理平台, 任务包括早餐、螺丝、插管、拆包、叠衣服和叠裤子。

指标: RoboTwin 50-task Easy/Hard=92.9/91.6; LIBERO 平均 98.5; 真实 6 任务每方法 20 trials, 论文/README 给出各任务 progress/success, 模型只需 50 demos/task, 异步推理约比同步快 2 倍。

研究判断: LingBot-VA 是 DreamZero 之前最完整的 causal AR WAM 工程化路线之一; 对灵巧手研究的直接价值在于数据尺度、action/world token 对齐和闭环记忆, 而非多指手硬件。

复现性判断: 高-中。Apache-2.0、代码、Hugging Face/ModelScope 权重和 RoboTwin/LIBERO 数据可用; 16K 小时内部预训练语料和真实硬件仍不可完全复刻。

关键限制或读者应注意: 论文正文没有把真实平台型号统一成一个可购买配置; 报告只写公开资料确认的“双臂物理平台”。

公开资料: 论文 | 代码/权重/数据 | 项目介绍

# DreamZero: World Action Models are Zero-shot Policies | 2026.02 / ICLR 2026

定位: 严格 WAM / 14B 视频-动作基础模型 | 公开状态: 代码、权重、预处理 DROID 数据公开; AgiBot 大规模数据与硬件门槛高

## 研究摘要

研究目的: 以 Wan2.1-I2V-14B 为 backbone, 采用 chunk-wise autoregressive flow matching, 联合生成 future video 和 action; KV cache、action chunk 和 action-only rollout 让一个 WAM 兼顾 zero-shot 控制与实时推理。

硬件与数据: AgiBot G1 mobile bimanual, 500 小时 teleop、7.2K episodes、22 environments; 测试 10 seen + 10 unseen tasks, 4 robots。Franka single-arm 用 DROID; 另用 YAM 双臂和人类 egocentric 数据做跨 embodiment。

指标: G1 seen/new environment task progress 62.2%, 最强预训练 VLA 27.4%; unseen tasks 39.5% 对 16.3%; DROID unseen task progress/success=49%/22.5%, 优于 GR00T 31%/12.5、pi0.5 33%/7.5。跨 embodiment 的 10-20 分钟视频微调可将 9 unseen tasks 从 38.3 提到 54.3-55.4。

效率与限制: 约 5.7s -> 150ms, 7 Hz; DreamZero-Flash 1-step 在 150ms 仍保留 74% task progress。模型 14B, 最低约 2 GPUs; AgiBot 500h 不完全公开, 真实规划仍受大模型硬件约束。

复现性判断: 中高。DROID 预处理数据、checkpoint、代码和推理路径完整, Apache-2.0; AgiBot 真实数据/硬件不完全公开, 完整 zero-shot 结果难复刻。

关键限制或读者应注意: DreamZero 不是多指灵巧手论文; 它更适合作为通用 WAM 数据与因果生成的上限参考。

公开资料: 论文 | 项目主页 | 代码/模型

# Dream-Tac: Unified Tactile World Action Model | 2026.06

定位: 严格触觉 WAM / 接触丰富操作 | 公开状态: 论文与 GitHub 公开; 数据集未见官方发布

## 研究摘要

研究目的: 在视觉 WAM 中加入 future tactile, 联合建模动作、未来视觉和未来触觉; 用 contact-aware attention、接触门控融合和 FlashBias/缓存加速来处理插入、切割、擦拭等 contact-rich task。

硬件与数据: Franka Panda, 固定第三人称 + wrist RealSense D435i, 指尖两个 Xense Photon 触觉传感器; 6 个真实任务, 每任务 100 demos、30 Hz、20 trials, SpaceMouse teleop。任务覆盖剥黄瓜、切香蕉、插 USB、麻将、取放/法棍、擦白板。

指标: Visual WAM/Cosmos 平均成功率 51.7%, 加入视觉-触觉 74.2%, Dream-Tac + CASA 83.3%; Dream-Tac 在 6 任务中 5 个最佳, OOD 对高度、外观、背景和放置变化更稳。训练最高约 2.9 倍加速, 推理 1.8 倍, 约 1109ms -> 619ms。

研究判断: Dream-Tac 把“未来会发生什么接触”明确纳入 WAM, 是从视频 WAM 走向物理接触 WAM 的关键一步; 但硬件是并联夹爪, 触觉数据和训练成本仍限制复现。

复现性判断: 中-低。训练/部署代码和配置公开, 但没有看到官方完整数据发布; 需要 Xense Photon/Franka 和 Cosmos backbone。

关键限制或读者应注意: 论文结果里“Pick and Place”和“Pick Baguette”有任务命名差异, 应以版本化数据和表格为准。

公开资料: 论文 | 代码

## EgoWAM: World Action Models Beyond Pixels | 2026.07

定位: 人类第一视角数据 + WAM 目标比较 | 公开状态: 论文/项目页公开; 代码页面标注 coming soon

### 研究摘要

研究目的: 研究什么 world target 最适合人类-机器人 co-training。比较 pixel VAE、DINO feature、camera-stabilized 3D motion flow; 世界 head 训练时存在, 推理时丢弃, 动作策略可 30 Hz 运行。

硬件与数据: 两台 upright 6-DoF ARX5 + parallel jaw grippers, Project Aria ego RGB、两只 wrist RealSense D405; Quest3 teleop。任务 cup-on-saucer、fold-clothes、bag-grocery, 每任务 300-360 robot demos, 约 2-3 小时 robot; EgoVerse 人类视频约 7-21 小时/task, 约 10:1 human:robot。

指标: 每任务 ID/OOD 各 20 rollouts、总 1,800; DINO 对 object/scene OOD 最强, 3D flow 让 ID 提升约 20-30%, 在非对齐人类数据下比 pixel 更稳。示例 aligned ablation 为 Pixel 35->65%、DINO 50->70%、3D flow 保持 85%。

研究判断: EgoWAM 给出了“训练 WAM、推理 action-only”的清晰因果研究设计, 对跨 embodiment 人类数据特别有价值; 但它是双臂并联夹爪、单任务策略, 不能直接证明多指灵巧性。

复现性判断: 中-低。数据入口和实验细节公开, 但项目页截至截点写 code coming soon; ARX5/Aria/wrist cameras 使硬件复现不低。

关键限制或读者应注意: 结果更像 world target 的控制变量实验, 而不是多任务、多手形态 WAM。

公开资料: 论文 | 项目主页 | EgoVerse 数据入口

## RepWAM: Representation Visual-Action Tokenizers | 2026.06

定位: 语义 visual-action latent / WAM 表示学习 | 公开状态: 论文、项目页、GitHub 仓库公开; 代码/权重发布状态仍在检查

### 研究摘要

研究目的: 反思重建导向的视频 VAE: 它保留像素细节, 却可能忽略对象关系和交互线索。RepViTok 用视觉 foundation feature 对齐 visual latent, 再学习 latent action token; WAM 先在语义 visual-action latent 上预训练, 再适配机器人动作。

硬件与数据: Franka dual-arm, 三项真实任务: pick fruit、push drawer、insert tube, 每任务 50 demos、10 rollouts。预训练约 100G AgiBot video-action latent tokens; 适配混合 AgiBot、RoboMIND、RoboCOIN、InternA1 约 300G tokens。模型 1.3B/5B, 训练 64/128 张 H20。

指标: 真实 5B pick/drawer/tube=60/80/60%; RoboTwin 2.0 50-task Easy/Hard=89.3/88.4; 1.3B 用 RepViTok 相对 WAN2.2 VAE 提升 Easy 78.0->86.6、Hard 76.0->83.1。

研究判断: RepWAM 和 LingBot-VA 2.0 共同说明: WAM 的瓶颈很可能在 visual-action tokenizer, 而不仅在 transformer 大小。对灵巧手研究, 语义 latent 需要进一步加入手指/接触 token。

复现性判断: 中-低。论文和结果完整, GitHub 存在; 但 README 在 2026-08 仍标注 inference code/weights release under inspect, 预训练语料和 H2O 集群不是普通复现条件。

关键限制或读者应注意: 它没有多指手或触觉实验, 应作为 WAM 表示路线而不是灵巧手结论。

公开资料: 论文 | 项目主页 | 代码仓库

## TouchWorld | 2026.07-08

定位: 预测触觉子目标 + 高速触觉残差的灵巧手系统 | 公开状态: 论文、项目主页公开; 未检索到官方代码/数据链接

### 研究摘要

研究目的: 把触觉拆成两种时间尺度: Tactile World Model 预测未来视觉-触觉子目标, nominal visuo-tactile policy 产出动作 chunk, tactile-conditioned refinement 在控制环中高速纠偏。

硬件与数据: humanoid platform + Wuji dexterous hands + JQ-Industries tactile glove; Meta Quest、Touch Plus、Wuji Glove teleoperation。TWM 先用 20.2 小时 EgoTouch 人类触觉视频预训练, 再用 10 小时 robot demos; robot 6 tasks, 每任务 200 teleop trajectories、100 evaluation rollouts。

指标: clean 平均成功率 65.0%, human perturbation 53.7%, 分别比最强 baseline 高 15.7 和 18.5 个百分点; TWM 的 temporal contact accuracy 86.3%、contact IoU 52.7%、volumetric IoU 43.8%。

研究判断: TouchWorld 比 Dream-Tac 更直接地展示了多指手、触觉和长时任务的系统组合, 但它是分阶段层级系统, 不是单一 end-to-end WAM; 对触觉传感器/手形迁移仍需校准和适配数据。

复现性判断: 低。硬件、数据格式、训练阶段的描述较充分, 但无官方代码/数据仓库, 完整复现依赖 Wuji/JQ-Industries 平台。

关键限制或读者应注意: 论文页显示的版本日期、项目页展示的任务素材可能随预印本更新; 报告按 2026-08-21 访问状态记录。

公开资料: 论文 | 项目主页

## N0-TWAM: Tactile-Native WAM | 2026.07

定位: 大规模触觉原生 strict WAM | 公开状态: 技术报告/arXiv、代码、checkpoint、post-training toolkit 公开; 不含大规模预训练管线

### 研究摘要

研究目的: 用 3-expert Mixture-of-Transformers 同时预测 future video、future tactile 和 action; 预测触觉提供 foresight, 当前观察触觉提供 reactive condition, contact event 负责长时 subtask 切换。模型约 7.16B, 视频 expert 5B、动作/触觉 expert 各约 1B。

数据与训练: NeoData 六个 embodiment、450 tasks, 约 7.5M clips, 每 clip 对齐多视角 RGB、per-finger tactile、语言和 20-D 双臂末端动作; 30K steps、128 H800。触觉用 InTac S1/NeoForce 表示, 仿真支持 UniVTAC/NeoSim。

硬件与指标: 真实 PiPER 和 Flexiv, 8 个 contact-rich tasks、每 task 20 trials; UniVTAC 84.5%、NeoSim 49.4%、真实平均 46.3%, 高于 pi0.5 30.0%、LingBot-VA 21.9%、FastWAM 14.4%。触觉消融显示预测/观察任一移除都会显著下降。

研究判断: N0-TWAM 是截至截点最“原生”地把触觉当作未来世界状态的 WAM 之一; 其优势在接触模糊、双臂协同和视觉扰动, 仍面临 128 H800 预训练、传感器覆盖和闭源 NeoData 的门槛。

复现性判断: 中等。代码、7.16B checkpoint、NeoSim/UniVTAC post-training 配置公开; 大规模 pretraining pipeline 和原始 NeoData 不公开, 训练成本极高, 且不是 anthropomorphic multi-finger hand 的独立评测。

关键限制或读者应注意: “tens of thousands hours” 是论文对规模的表述，项目页同时给出 7.5M clips；不要自行把 clip 数换算成小时。

公开资料: 论文/技术报告 | 项目主页 | 代码 | checkpoint

## Wh0: Generative World Models as Human-Hand Data Sources | 2026.06

定位: 世界模型生成灵巧手人类视频的相邻路线 | 公开状态: 论文、项目页、GitHub 公开；50k 数据需本地生成

### 研究摘要

研究目的: 不把世界模型当机器人控制器，而是把它变成可控的人手数据工厂。Wh0 生成 WM-H 50k episodes，包含 egocentric 视频、语言和 3D hand motion，再与少量真实机器人数据共训 dexterous VLA。

硬件与数据: Unitree G1 + Inspire dexterous hands, Vision Pro ego camera; 400 条真实 expert trajectories; WM-H 约 50k episodes, 由 instruction generation、scene edit、Wan-l2V、Qwen-Image-Edit、HaWoR/MANO motion reconstruction 组成。

指标: 18 个真实任务、每任务 20 trials、zero-shot; VITRA 仅 human+teleop 8.3%，加入真实 ego 21.4%，加入 WM-H 38.9%，提升约 4.7 倍。

研究判断: Wh0 补上了“WAM 如何为多指手扩展数据”的一环，但它不是 strict WAM；价值在场景/形态对齐和数据规模，风险是合成手-物接触的真实性和生成成本。

复现性判断: 中高。端到端生成、标注、训练流程和 debug 资产公开，支持单 80GB GPU smoke test；完整 50k 生成仍需较大显存、外部权重和 G1/手部部署。

关键限制或读者应注意: 合成数据提升 VLA 并不等于世界模型已学会真实手指接触动力学。

公开资料: 论文 | 项目主页 | 代码

## 3.1 同期最新 WAM 主线：LingBot-VA 2.0

2026 年 7 月的 LingBot-VA 2.0 把 RepWAM 的语义 visual-action tokenizer、causal pretraining、sparse MoE、multi-chunk prediction 和 Foresight Reasoning 组合成“为 embodiment 原生预训练”的方向。论文自报只需 10-15 demos，异步执行峰值 225 Hz，并把人类视频的 latent action 作为自监督信号。它还没有像 N0-TWAM 一样把触觉纳入公开架构，也没有在当前截点给出同等完整的公开训练管线，因此本报告把它视为最新趋势和后续高优先级跟踪对象，而非已经完全可复现的多指手结果。

公开资料: 论文 | 项目页

# 4. 统一比较：硬件、数据、目标与指标

## 4.1 硬件覆盖

| 硬件层     | 代表工作                                                                                      | 已验证能力                                  | 与多指灵巧手的关系                                |
|---------|-------------------------------------------------------------------------------------------|----------------------------------------|------------------------------------------|
| 多指/灵巧手  | VPP-XHand; Cross-Embodiment Ability/XHand; DexWM Allegro; TouchWorld Wuji; Wh0 G1-Inspire | 抓取、重塑、细粒度 hand-object interaction、触觉接触 | 直接相关；但任务、传感器与动作接口差异很大                    |
| 并联夹爪/单臂 | UWM; Cosmos; Dream-Tac; DexWM bridge                                                      | 插入、擦拭、堆叠、长时顺序与接触                       | 适合验证 WAM 训练目标和闭环机制，不应直接代替多指结果            |
| 双臂/移动双臂 | UVA; LingBot-VA; DreamZero; EgoWAM; RepWAM; N0-TWAM                                       | 双臂协调、长时任务、跨 embodiment、异步执行            | 提供规模化 WAM 上限，但 hand morphology 多为末端/平行夹爪 |

4.2 数据来源与监督形态

| 数据类型             | 优点               | 主要风险                  | 典型工作                                    |
|------------------|------------------|-----------------------|-----------------------------------------|
| 真实机器人 teleop     | 动作可执行、观测和动作对齐    | 昂贵、跨硬件不共享、任务覆盖窄       | VPP, UWM, Dream-Tac, TouchWorld, EgoWAM |
| 人类第一视角视频         | 规模大、手-物行为丰富      | 人手到机器人手的形态/视角/动作错位    | DexWM, EgoWAM, DreamZero, Wh0           |
| 多 embodiment 机器人 | 可学共享动作/动态接口      | 数据格式、动作空间和传感器异构       | LingBot-VA, DreamZero, N0-TWAM          |
| 仿真/合成            | 可扩展、可控、标签齐全      | sim-to-real、视觉/接触分布偏差 | Cross-Embodiment, DexWM, DWM, RoboTwin  |
| 触觉同步数据           | 可观测滑移、载荷、插入/接触状态 | 传感器专用、规模小、采集难         | Dream-Tac, TouchWorld, N0-TWAM          |

4.3 未来目标和动作接口

| 目标                           | 优势                 | 缺陷                 | 适合的灵巧手研究问题           |
|------------------------------|--------------------|--------------------|----------------------|
| 像素/视频 latent                 | 借用大规模视频先验，视觉直观     | 外观和物理纠缠，视频漂移，推理慢   | 长时任务、物体语义和粗粒度未来      |
| DINO/语义 visual-action latent | 更关注对象/关系/指令，OOD 更稳 | 可能丢失接触细节和几何精度      | 目标对象选择、任务泛化、语言对齐     |
| 3D flow/particle/point       | 跨手形、接触几何、形变更可解释    | 状态估计和动作解码成本高       | 多指手形态迁移、塑形、推/拨/非抓取操作 |
| hand keypoint / HC loss      | 直接约束手的结构和时序        | 依赖检测/重建，难处理遮挡和真实接触 | 手指协调、手-物交互、人体到机器人迁移  |
| future tactile               | 提前预测滑移、载荷、接触事件     | 传感器专用、数据与标定昂贵      | 精插入、柔性物体、力控制、失败恢复    |

5. 可复现程度与公开资产审计

5.1 评估方法

本报告采用四项各 0-2 分的简化量表：A=代码/权重是否可运行，B=训练/评测数据是否公开，C=硬件与 benchmark 是否标准化，D=训练算力、配置和文档是否足以复现。总分 0-8：高（6-8）、中（4-5）、低（0-3）。这不是科学的绝对量化，而是帮助研究者选择“先复现什么”。

| 工作               | A 代码/权重 | B 数据 | C 硬件/基准 | D 算力/配方 | 总分  | 判断  |
|------------------|---------|------|---------|---------|-----|-----|
| VPP              | 1       | 1    | 1       | 1       | 4/8 | 中   |
| UVA              | 2       | 1    | 1       | 1       | 5/8 | 中高  |
| UWM              | 2       | 2    | 1       | 1       | 6/8 | 高-中 |
| Cross-Embodiment | 0       | 0    | 1       | 1       | 2/8 | 低   |
| DexWM            | 2       | 2    | 1       | 0       | 5/8 | 中   |
| DWM              | 2       | 1    | 1       | 1       | 5/8 | 中   |
| Cosmos Policy    | 2       | 2    | 2       | 1       | 7/8 | 高-中 |
| LingBot-VA       | 2       | 1    | 2       | 2       | 7/8 | 高-中 |
| DreamZero        | 2       | 1    | 1       | 2       | 6/8 | 中高  |
| Dream-Tac        | 1       | 0    | 1       | 1       | 3/8 | 中-低 |
| EgoWAM           | 0       | 1    | 1       | 1       | 3/8 | 中-低 |
| RepWAM           | 1       | 0    | 1       | 1       | 3/8 | 中-低 |
| TouchWorld       | 0       | 0    | 1       | 1       | 2/8 | 低   |
| N0-TWAM          | 2       | 0    | 1       | 2       | 5/8 | 中   |
| Wh0              | 2       | 1    | 1       | 2       | 6/8 | 中高  |

5.2 复现优先级

如果目标是尽快得到可重复的 WAM baseline，优先级建议如下：

- 第一梯队: UWM（LIBERO/DROID）和 Cosmos Policy（LIBERO/RoboCasa），前者训练成本低、后者公开资产最完整。

- 第二梯队: DexWM（先只跑 EgoDex/RoboCasa 小子集）和 UVA（理解联合 latent、forward/inverse dynamics）。
- 第三梯队: N0-TWAM 的 post-training/NeoSim 和 Wh0 的 synthetic pipeline；能验证触觉原生或合成数据，但需要更强 GPU/外部权重。
- 研究复现而非系统复现: Cross-Embodiment、TouchWorld、Dream-Tac。先按论文实现表示和损失，再在公开仿真手上验证，不应承诺完全复刻真实平台结果。

5.3 公开资料中的常见缺口

| 缺口           | 影响                     | 建议的复现记录                                                                 |
|--------------|------------------------|-------------------------------------------------------------------------|
| 只发布模型不发布原始数据 | 无法判断数据偏差、分割、去重和真实规模    | 记录下载时间、样本数、采样率、任务/形态分布，发布最小可用 subset                                    |
| 真实硬件型号/标定不完整 | 动作尺度、相机位姿和触觉归一化难以匹配    | 公开 URDF、相机内外参、动作单位、控制频率和 safety limit                                   |
| 只报成功率        | 看不出接触失败、滑移、动作延迟、视觉幻觉   | 同时报 progress、contact event、slip、PCK/3D error、latency 和 failure taxonomy |
| 视频未来与动作执行不同步 | 模型看似预测正确，闭环却因 drift 失败 | 报告 action horizon、requery rate、KV cache、re-grounding 和 rollout drift    |
| 论文/项目页版本不一致  | 复现数字随 v1/v2、项目页更新而变化   | 绑定 arXiv 版本、commit hash、checkpoint SHA 和数据 manifest                     |

6. 面向灵巧手的研究建议

6.1 推荐的最小可复现路线

| 阶段        | 目标                                          | 建议配置                                                          | 通过标准                                           |
|-----------|---------------------------------------------|---------------------------------------------------------------|------------------------------------------------|
| S0 基线     | 复现 WAM 的联合训练与 action-only 推理                | UWM/LIBERO 或 DROID, 2-4 A100; 先不做真实机器人                        | 复现 success/未来预测趋势, 记录端到端 latency               |
| S1 灵巧手表示  | 把手关键点、物体点云/3D flow、proprio 加入 future target | SAPIEN + Allegro/Leap/XHand/Ability; 小模型 100M-1B              | unseen hand MSE、PCK、CD/EMD 和 task success 同步改善 |
| S2 人类到机器人 | 用 EgoDex/人类视频学习手-物动态, 再用少量 robot data 解码动作  | DexWM-style latent WM + 4h RoboCasa bridge                    | 同一 world model 支持至少两种手形, OOD object/scene 不崩   |
| S3 接触原生   | 加入触觉未来和 contact event, 动作仍 action-only 实时解码 | Dream-Tac/N0-TWAM-style tactile branch; 先用 pressure/force map | insert/slip/load/wipe 任务中触觉消融显著                |
| S4 真实闭环   | MPC 与异步 WAM 二选一, 再做安全和失败检测                  | 真实 Allegro/Ability/XHand + 多视角 RGB-D + tactile                | 报告 20-50 trials、OOD、失败类型、延迟和恢复率                |

6.2 建议的 PyTorch 模型骨架

一个务实的研究原型可以不从 5B 视频生成器起步：

- 输入编码: RGB/DINO patch + 3D hand keypoints/flow + object point/pose + proprio；若有触觉，统一成 per-finger pressure/force map。
- 共享 causal transformer: 当前历史作为 context，预测未来表征  $z(t+1:t+H)$  和动作 chunk  $a(t:t+H-1)$ ；动作 head 在训练时读取预测未来，推理时可跳过未来解码。
- 损失: action flow/diffusion + future representation loss + hand consistency/PCK + contact-event classification + optional tactile future loss；不要只用 pixel MSE。
- 部署: 先 action-only 30 Hz，再增加少量候选未来做 best-of-N/MPC；异步 rollout 必须用最新真实 observation re-ground。
- 数据切分: ID/OOD 按物体、场景、手形、相机和接触状态分别切分；必须公开 manifest、动作单位、相机参数和失败标签。

6.3 建议的统一指标

| 层次    | 最小指标集                                                               | 回答的问题                              |
|-------|---------------------------------------------------------------------|------------------------------------|
| 动作/任务 | success、task progress、每阶段 success、20-50 trials CI                   | 策略是否真正完成任务，长时在哪个阶段失败               |
| 手-物状态 | PCK@20、hand/keypoint L2、object pose/point CD、EMD                    | 未来 hand-object dynamics 是否细粒度且可跨手形 |
| 接触    | contact onset F1、slip rate、load/force error、insertion alignment     | 模型是否理解视觉不可见接触状态                    |
| 生成/预测 | latent L2、PSNR/SSIM/LPIPS/gFVD 仅作参考                                 | 未来表征或视频是否稳定；不能替代控制指标               |
| 系统    | requery Hz、action latency、planning time、GPU memory、failure recovery | 能否安全、实时地运行在机器人上                    |

7. 结论

从研究史看，WAM 已经完成了三个关键转折：第一，视频预测不再只用于生成视觉，而成为动作策略的预测表征；第二，视频和动作被放进共同的 latent/因果序列，世界模型开始直接约束动作；第三，语义 visual-action、3D particle 和触觉未来开始替代单纯像素重建，世界模型逐渐靠近真实物理交互。

从灵巧手看，真正的难点仍是手指级接触和跨形态动作落地。当前最可信的技术组合不是单独放大视频模型，而是：3D/hand-aware 表示负责形态与几何，语义 latent 负责任务和 OOD，触觉未来负责接触，因果/异步执行负责实时闭环，少量真实数据负责最后的动作 grounding。

因此，如果研究目标是“机器人灵巧手 + WAM”，建议把贡献定义在可验证的中间问题上：未来 hand-object state 是否可预测、是否能跨手形态、是否能识别接触事件、是否能减少真实 demos、是否能在 action-only 推理下保持稳定。只报更高的 success rate，不足以说明 WAM 学到了灵巧操作。

附录 A. 证据台账与公开链接

下表按研究条目列出本报告实际使用的公开资料。论文链接优先采用 arXiv abstract/HTML，项目/代码/数据链接采用作者或组织的官方页面。页面状态以 2026-08-21 访问为准。

| 编号    | 工作                  | 论文原文  | 项目/数据      | 代码/权重          |
|-------|---------------------|-------|------------|----------------|
| [R1]  | VPP                 | arXiv | 打开         | 打开             |
| [R2]  | UVA                 | arXiv | 打开         | 打开             |
| [R3]  | UWM                 | arXiv | 打开         | 打开             |
| [R4]  | Cross-Embodiment WM | arXiv | 打开         | 未检索到官方代码/数据仓库  |
| [R5]  | DexWM               | arXiv | 打开         | 打开   打开        |
| [R6]  | DWM                 | arXiv | 打开         | 打开             |
| [R7]  | Cosmos Policy       | arXiv | 打开         | 打开             |
| [R8]  | LingBot-VA          | arXiv | 打开         | 打开             |
| [R9]  | DreamZero           | arXiv | 打开         | 打开             |
| [R10] | Dream-Tac           | arXiv | 未检索到独立项目主页 | 打开             |
| [R11] | EgoWAM              | arXiv | 打开         | 打开             |
| [R12] | RepWAM              | arXiv | 打开         | 打开             |
| [R13] | TouchWorld          | arXiv | 打开         | 未检索到官方代码/数据链接  |
| [R14] | N0-TWAM             | arXiv | 打开         | 打开   打开        |
| [R15] | Wh0                 | arXiv | 打开         | 打开             |
| [R16] | LingBot-VA 2.0      | arXiv | 打开         | 截至截点未见完整官方训练代码 |

## 附录 B. 版本与不一致项记录

- VPP: XHand 数据规模与类别数在正文/补充材料不同，报告用正文并提示差异。
- DWM: Aria 动态评测样本在正文与附录出现 60/48 两种表述，报告不强行合并。
- Dream-Tac: 论文不同位置出现 Pick and Place/Pick Baguette，报告使用两种名称并提示。
- N0-TWAM 与 TouchWorld 是截至截点较新的预印本/技术报告，指标应视为公开版本自报，后续版本可能变化。
- 所有复现性等级基于访问时的公开网页和仓库，不代表作者承诺的未来发布状态。

报告完